

Relatório – RT-DETR-L no WoodScape

Matheus Higino

14 de setembro de 2026

1. Objetivo

Este experimento avaliou o modelo RT-DETR-L para detecção de objetos em imagens fisheye do dataset WoodScape. O objetivo foi estabelecer uma configuração de referência para futura comparação com modelos YOLO, utilizando uma divisão fixa dos dados em treinamento, validação e teste.

Foram consideradas cinco classes: `vehicles`, `person`, `bicycle`, `traffic_light` e `traffic_sign`.

2. Configuração experimental

O WoodScape foi dividido em 6.587 imagens de treinamento, 823 de validação e 824 de teste, correspondendo aproximadamente a uma divisão 80/10/10. O conjunto de teste foi preservado e ainda não foi utilizado nos resultados apresentados.

Neste experimento, foi utilizada a variante RT-DETR-L (*Large*) do RT-DETR original [1], carregada a partir dos pesos pré-treinados `rtdetr-1.pt`. O modelo foi posteriormente ajustado ao dataset WoodScape para as cinco classes consideradas neste estudo.

O treinamento foi executado em uma NVIDIA GeForce RTX 5070, utilizando imagens de entrada com tamanho 640, batch size 8 e otimizador AdamW.

Tabela 1: Principais parâmetros do experimento.

Parâmetro	Valor
Modelo	RT-DETR-L (Large)
Pesos iniciais	<code>rtdetr-1.pt</code>
Épocas máximas	100
Batch size	8
Image size	640
Otimizador	AdamW
Learning rate inicial	0,001
Weight decay	0,0005
Warm-up	3 épocas
Early stopping (paciente)	20 épocas
Seed	42
AMP	habilitado

O treinamento foi interrompido automaticamente na época 91 por *early stopping*. A melhor época foi a 71, e o modelo correspondente foi salvo em `best.pt`.

3. Resultados

A validação final do melhor modelo foi realizada sobre 823 imagens e 7.117 instâncias.

Tabela 2: Resultados globais de validação.

Métrica	Resultado
Precision	0,655
Recall	0,593
mAP@50	0,618
mAP@50:95	0,394
Inferência	5,8 ms/imagem
Parâmetros	31,99 milhões
GFLOPs	105,4

Os resultados por classe foram:

Tabela 3: Resultados por classe.

Classe	P	R	mAP@50	mAP@50:95
vehicles	0,769	0,753	0,802	0,608
person	0,759	0,667	0,739	0,448
bicycle	0,594	0,456	0,504	0,312
traffic_light	0,605	0,486	0,469	0,235
traffic_sign	0,545	0,601	0,574	0,367

A classe **vehicles** apresentou o melhor desempenho, enquanto **traffic_light** apresentou o menor mAP. O desbalanceamento entre classes provavelmente contribuiu para essa diferença, embora fatores como tamanho aparente, distorção fisheye e oclusões também possam influenciar.

4. Interpretação

As perdas de treinamento continuaram diminuindo até o final, porém as métricas de validação atingiram um platô aproximadamente entre as épocas 60 e 70. O melhor resultado foi registrado na época 71, e as épocas posteriores não trouxeram melhora consistente.

Esse comportamento indica saturação do treinamento e possível início de sobreajuste, justificando o uso do *early stopping*. O treinamento completo apresentou melhora em relação ao *smoke test* inicial de três épocas, especialmente em mAP@50:95, que passou de 0,347 para 0,394.

É importante destacar que estes resultados são de **validação**, não de teste final. Também não foi realizada validação cruzada; foi utilizada uma divisão fixa *train/validation/test*.

5. Próximas etapas

Os próximos passos são avaliar o **best.pt** no conjunto de teste, analisar curvas de Precision-Recall, F1 e matriz de confusão, e então repetir o protocolo com YOLO utilizando exatamente os mesmos *splits*. A comparação deverá considerar mAP@50, mAP@50:95, Precision, Recall, latência, FPS, parâmetros, GFLOPs, uso de VRAM e tamanho do modelo.

Resumo: o RT-DETR-L apresentou mAP@50 de 0,618 e mAP@50:95 de 0,394 no conjunto de validação, com melhor desempenho na classe **vehicles**. O experimento confirmou uma configuração estável para servir como baseline nas próximas comparações.

Referências

- [1] W. Lv, S. Xu, Y. Zhao, G. Wang, J. Wei, C. Cui, Y. Du, Q. Dang e Y. Liu, *DETRs Beat YOLOs on Real-time Object Detection*, arXiv preprint arXiv:2304.08069, 2023.